

Clasificación de los grados de retinopatía diabética en imágenes del fondo del ojo mediante algoritmos de aprendizaje profundo.

G. T. Diego.

Centro de Investigación en Computación

Examen a Puerta Cerrada, Noviembre 2020



Tabla de contenidos

- 1 Hipótesis
- 2 Justificación
- 3 Objetivos
- 4 Estado del Arte
 - Marco de trabajo
 - RNA
- 5 Antecedentes
- 6 Metodología
- 7 Resultados experimentales
- 8 Conclusiones y trabajo a futuro
- 9 Bibliografía



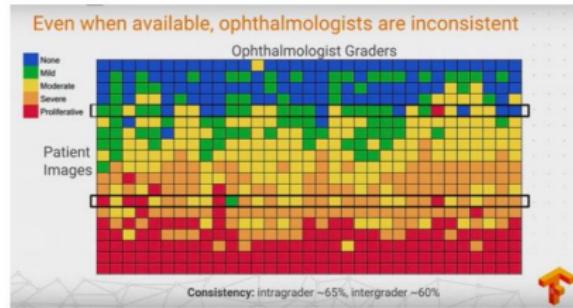
Hipótesis

- En este trabajo de investigación se presenta un método computacional para clasificar las diferentes etapas de la retinopatía diabética en imágenes del fondo del ojo, las cuales presentan diferentes grados de lesiones como los microaneurismas, exudados y hemorragias.
- Se utiliza el marco de trabajo del aprendizaje profundo como herramienta para resolver dicho problema, en particular las redes neuronales convolucionales.



Justificación

- Reducción de costos y optimización de los recursos, minimización del número de oftalmólogos y el tiempo de diagnóstico debido a que los especialistas reciben cada vez más imágenes debido al crecimiento de los pacientes con diabetes de acuerdo con la OMS.[1]
- Hasta el 56% de los casos pueden ser reducidos con una detección temprana.[2]



J. Krause, V. Gulshan, E. Rahimy, P. Karth, K. Widner, G. S. Corrado, L. Peng, and D. R. Webster, "Grader variability and the importance of reference standards for evaluating machine learning models for diabetic retinopathy," *Ophthalmology*, vol. 125, no. 8, p. 1264–1272, Aug 2018. [Online]. Available : <http://dx.doi.org/10.1016/j.ophtha.2018.01.03>



Motivación

- En México se estima hay 12 millones de personas viviendo con diabetes y cerca de otros 12 millones con prediabetes. De ellas, unos cuatro millones están en riesgo de desarrollar en el corto plazo retinopatía diabética.
- Si la retinopatía diabética se diagnosticara en forma temprana y se tratara oportunamente, el sistema público de salud del país podría ahorrarse unos 3,000 millones de pesos anuales.
- Prosperia en conjunto con APEC, ITAM, UNAM.

M. R. Coronel, "Aplican inteligencia artificial para detectar riesgo de ceguera causada por diabetes," Octubre 2020.[Online]. Available: <https://www.eleconomista.com.mx/opinion/Aplican-inteligencia-artificial-para-detectar-riesgo-de-ceguera-causada-por-diabetes-20201002-0031.html>

The screenshot shows a news article from 'EL ECONOMISTA' with the following details:

- Header:** EL ECONOMISTA
- Section:** SALUD Y NEGOCIOS
- Title:** Aplican inteligencia artificial para detectar riesgo de ceguera causada por diabetes
- Text:** Cuatro millones de mexicanos están en riesgo de desarrollar retinopatía diabética, y no lo saben. Cuando se enteran ya está muy avanzada y no hay forma de revertirla.
- Author:** Maribel Ramírez Coronel
- Date:** 02 de octubre de 2020, 08:22
- Social sharing icons:** Facebook, Twitter, Email

Objetivo Generales

General

- Diseñar una metodología basada en aprendizaje profundo, es decir, utilizar alguna red neuronal convolucional en conjunto con otras técnicas para ayudar a los expertos en el diagnóstico de la de las diferentes etapas de la retinopatía diabética y que permita el diagnóstico temprano de la enfermedad.



Objetivo particulares

- Estudiar el estado del arte de las redes neuronales convolucionales.
- Investigar el trabajo previo en el contexto computacional para la resolución de la detección y clasificación de la retinopatía diabética.
- Realizar un preprocesamiento efectivo y analizar los datos para obtener un mejor desempeño en la clasificación automática de retinopatía diabética.
- Probar diferentes técnicas de preprocesamiento y aumentación de datos y regularización para mejorar el rendimiento de la red neuronal.
- Implementar una red neuronal convolucional y establecer una métrica que ayude a resolver el problema de clasificación.
- Programar la red neuronal convolucional en un framework de machine learning como tensorflow, pytorch, keras.
- Comparar los resultados obtenidos con los métodos del estado del arte, de acuerdo a las métricas de desempeño como exactitud, kappa, recall, etc.



Retinopatía Diabética

La retinopatía diabética (RD) es una complicación visual, crónica y específica de la diabetes mellitus, se presenta cuando son dañados los vasos sanguíneos que se encuentran en la retina a causa de altos niveles de glucosa en la sangre. Con el tiempo la RD puede causar una pérdida en la visión o incluso provocar ceguera.

Tipos o grados de severidad:

Sin Retinopatía	Sin anormalidades	0	[1,0,0,0,0]
No Proliferativa Leve	Solo aneurismas	1	[0,1,0,0,0]
No Proliferativa Moderada	Más que solo aneurismas	2	[0,0,1,0,0]
No Proliferativa Severa	Más de 20 hemorragias intraretinales en cada uno de los 4 cuadrantes. Rosarios venosos definidos en 2 o más cuadrantes. IRMA prominente en uno o más cuadrantes.	3	[0,0,0,1,0]
Proliferativa	Hemorragia preretinal Neovascularización	4	[0,0,0,0,1]

N. E. Institute, "La retinopatía diabética, lo que usted debe de saber," 2017.[Online].Available:
<https://www.nei.nih.gov/learn-about-eye-health/resources-for-health-educators/outreach-materials/la-retinopatia-diabetica-lo-que-usted-debe-saber-diabetic-retinopathy-what-you-should-know>



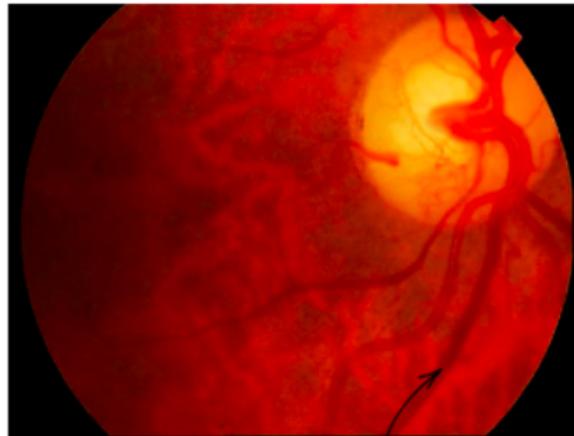
Ejemplo

Retinopatía Diabética

No proliferativa



Proliferativa



Aneurisma

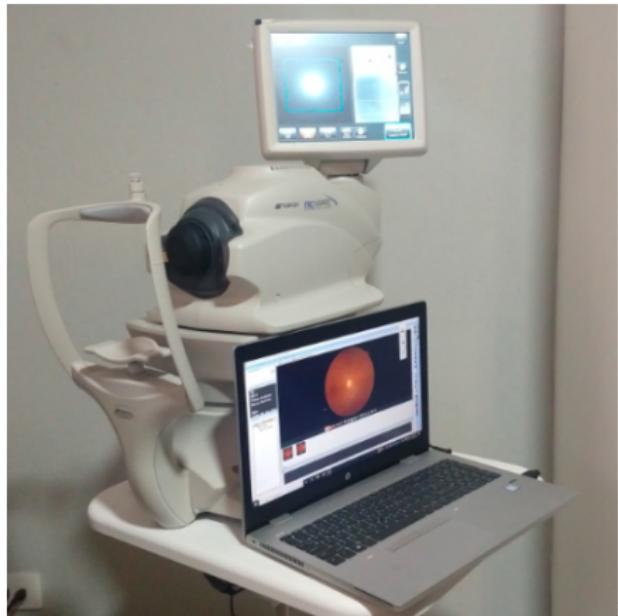
Hemorragia

Exudado

Crecimiento anormal de los vasos sanguíneos



Dispositivos



1



2

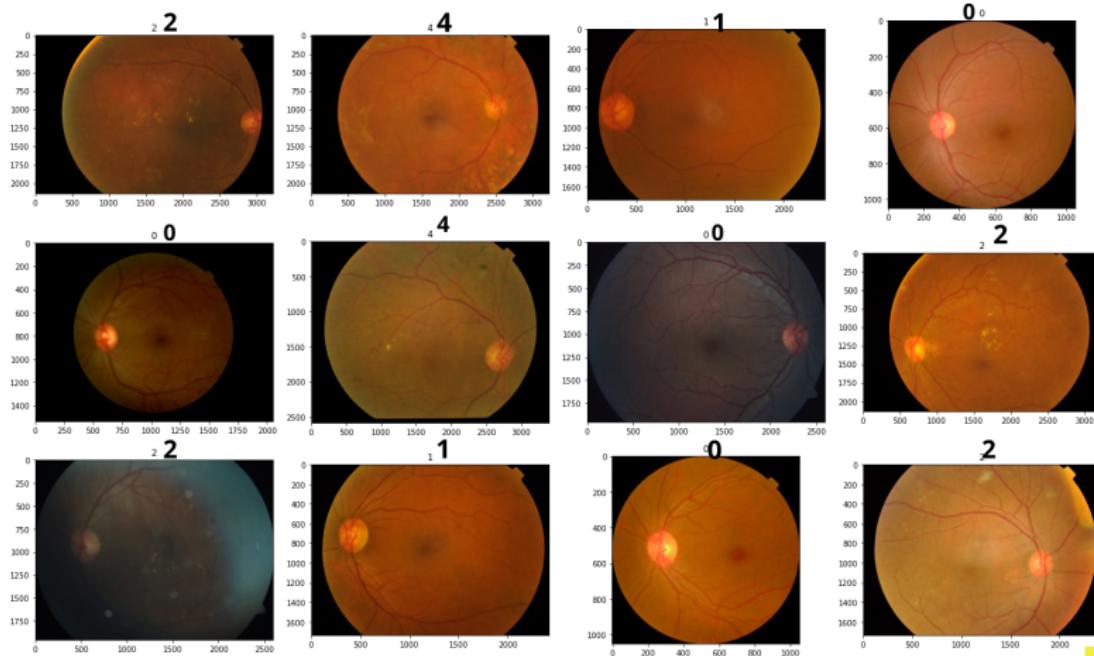
1 Imagen tomada de <https://www.liderempresarial.com/oftalmologos-utilizan-inteligencia-artificial-para-prevenir-casos-de-ceguera-en-aguascalientes/>

//www.liderempresarial.com/oftalmologos-utilizan-inteligencia-artificial-para-prevenir-casos-de-ceguera-en-aguascalientes/

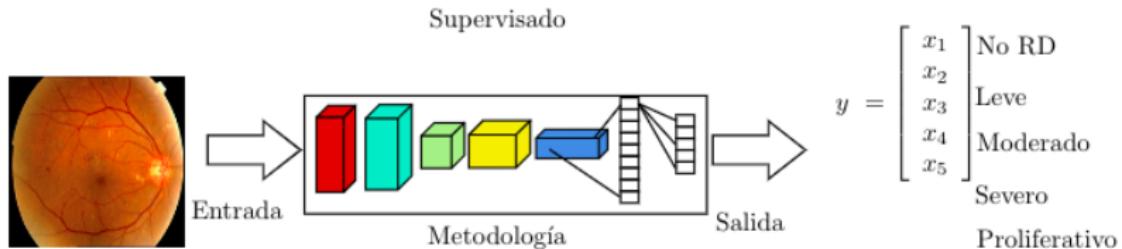
2 Imagen tomada de <https://odocseyecare.shop/products/odocs-nun>



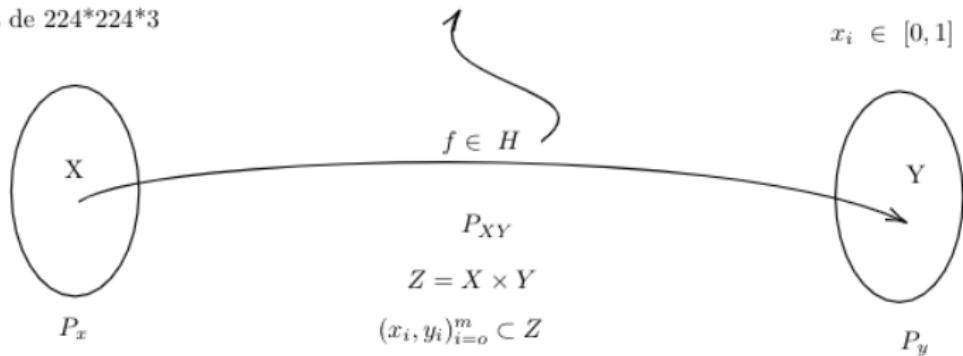
Ejemplos del conjunto de datos



Marco de trabajo



Matriz de $224 \times 224 \times 3$



$$\text{Perdida} = - \sum_{i=0}^C t_i \log(f(x)_i) \quad f(x)_i = \frac{e^{x_i}}{\sum_j e^{x_j}}$$



Generalización

Teorema. Desigualdad de Vapnik-Chervonenkis

Para cualquier $\epsilon > 0$ y para toda $g \in H$ se tiene que:

$$\mathbb{P}[|E_{\text{in}}(g) - E_{\text{out}}(g)| > \epsilon] \leq 2m_{\mathcal{H}}(N)e^{-2\epsilon^2 N}$$

donde:

N el número de ejemplos

$m_{\mathcal{H}}$ es la función de crecimiento dado un espacio de hipótesis

- V. Vapnik, Statistical learning theory, John Wiley & Sons, 1998. MR 99h:62052
- Cucker and S. Smale. On the mathematical foundations of learning. American Mathematical Society, 39(1):1–49, 2002.

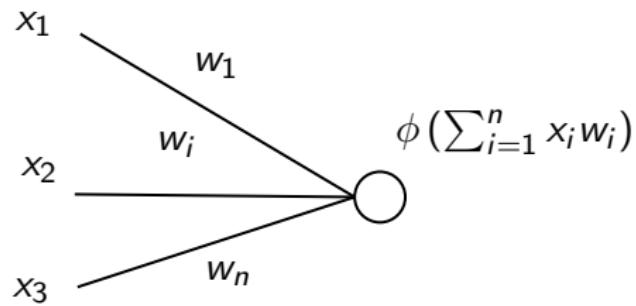


Red Neuronal Artificial

$$f(\mathbf{x}; \mathbf{w}, b) = \phi \left(b + \sum_{i=1}^n x_i w_i \right)$$

donde ϕ es una función no lineal.

b corresponde a un parámetro extra llamado bias.



Redes Neuronales Convolucionales

Convolución

$$f * g = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

Convolución Discreta

$$f * g = \sum_{-\infty}^{\infty} f(k)g(n - k)$$

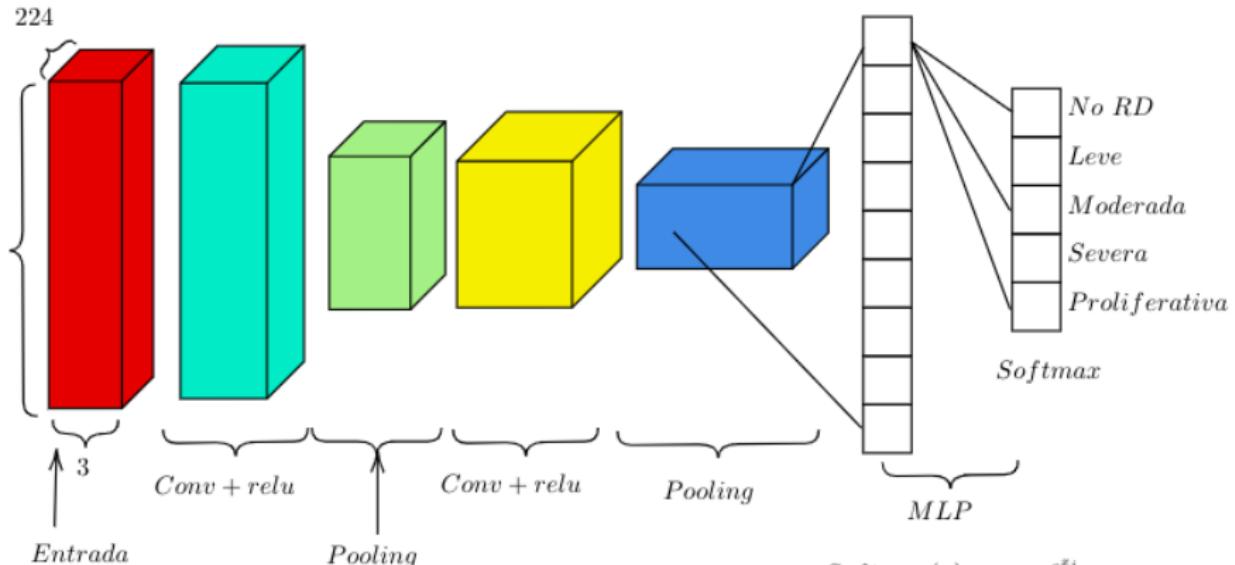
Convolución 2D Discreta

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n)K(m, n)$$

K. Fukushima and S. Miyake, "Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition," in Competition and Cooperation in Neural Nets, S.-i. Amari and M. A. Arbib, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 1982, pp. 267–285.



Arquitectura de una Red neuronal convolucional



$$\text{Softmax}(x)_i = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$



Ejemplo de convolución

$$\begin{array}{|c|c|c|c|} \hline 1 & 2 & 3 & 4 \\ \hline 2 & 4 & 3 & 1 \\ \hline 4 & 1 & 2 & 3 \\ \hline 2 & 3 & 1 & 4 \\ \hline \end{array} I \quad * \quad \begin{array}{|c|c|c|} \hline 1 & 0 & 1 \\ \hline 0 & 1 & 0 \\ \hline 1 & 0 & 1 \\ \hline \end{array} K = \begin{array}{|c|c|} \hline 14 & 13 \\ \hline 9 & 14 \\ \hline \end{array} Y$$

$$\begin{aligned}
 Y(0,0) &= I(0,0)K(0,0) + I(0,1)K(0,1) + I(0,2)K(0,2) \\
 &\quad + I(1,0)K(1,0) + I(1,1)K(1,1) + I(1,2)K(1,2) \\
 &\quad + I(2,0)K(2,0) + I(2,1)K(2,1) + I(2,2)K(2,2) \\
 &= 14
 \end{aligned}$$

$$\begin{aligned}
 Y(0,0) &= 1(1) + 2(0) + 3(1) + \\
 &\quad 2(0) + 4(1) + 3(0) + \\
 &\quad 4(1) + 1(0) + 2(1) + \\
 &= 14
 \end{aligned}$$

$$Y(x, y) = \sum_j \sum_i I(x + i, y + j) K(i, j)$$



Operación de Agrupamiento

Mapa de características
rectificado

1	4	2	7
2	8	8	5
3	4	0	7
1	2	3	1

Mapa de
características
agrupado

Agrupación máxima con filtros
de 2x2 y paso de 2

6	8
4	7

$$Max(3, 4, 1, 2)$$



Estado del arte de RNC

- LeNet5 (1994) [3]
- Dan Ciresan Net (2010) [4]
- AlexNet (2012) [5]
- VGG (2015) [6]
- NiN (2014) [7]
- Inception (2014) [8]
- ResNet (2015) [9]
- DenseNet (2016) [10]
- EfficientNet (2020) [11]



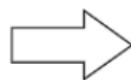
Antecedentes

Resultados	(A)	(S)	(E)	Problema	Algoritmo	BD
(Gardner et al., 1996)	-	.88	.83	Si/no	SVM	200
(Nayak et al., 2008)	.93	.9	1	3 Clases	NN	120
(Charya et al., 2009)	.82	-	.88	5 Clases	SVM	-
(Pratt et al., 2016)	.75	.3	.95	5 Clases	CNN	80,000
(Shaohua et al., 2018)	.73-.86	.39-.73	.79-.82	5 Clases	AlexNet, VGG, GoogleNet	EyePACS
(Lam et al., 2018)	.49-.72	-	-	2,3,4 Clases	GoogleNet	EyePACS Messidor
(Hagos et al., 2019)	.909			2 Clases	Inception-V3	5000
(Sarki et al., 2019)	.813	-	-	5 clases	Varias	EyePACS Messidor

Se puede observar el conjunto de datos utilizado y los problemas que se trataron de solucionar, donde EyePACS tenía 35,126 imágenes y Messidor 1748 imágenes. (A) significa exactitud o accuracy en inglés, (S) sensibilidad y (E) especificidad.



Metodología



Entrada



Preprocesamiento

Red Neuronal Convolucional



Salida

Vector de
probabilidades

$$y = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix}$$

No RD
Leve
Moderado
Severo
Proliferativo

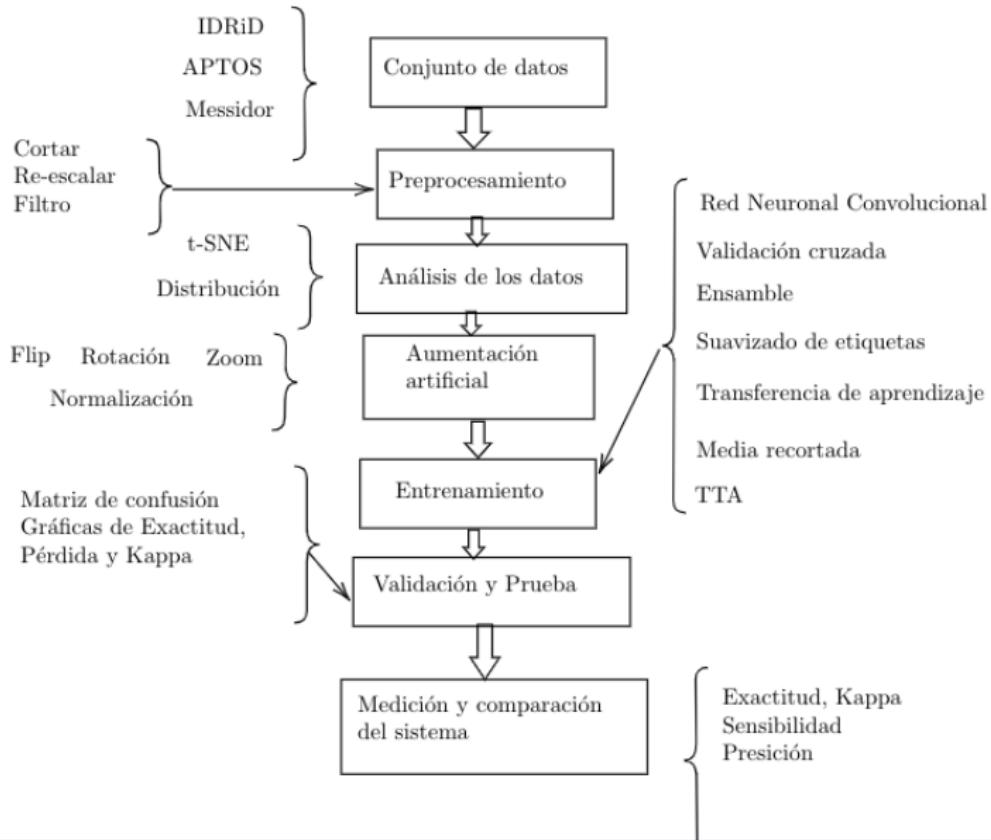
$$x_i \in [0, 1]$$

$$\max(x_1, x_2, x_3, x_4, x_5)$$

Matriz de 224*224*3



Metodología



Implementación

Dataset	datos	
APTOS	3662	Asia Pacific Tele-Ophthalmology Society
EyePacs	35124	California Healthcare Foundation
IDRiD	516	clínica oftalmológica en Nanded,Maharashhra, India
Messidor	1748	Hospital Universitario de Brest en francia

La solución se implemento en dos computadoras diferentes, una se utilizo para el preprocesamiento de los datos y tiene las siguientes características:

- Procesador Intel Core i5 - 1.6 GHz
- Memoria RAM de 8 GB-1600 MHz DDR3



Implementación

El sistema operativo de la primer computadora es macOS Mojave versión 10.14.6

La segunda computadora se utilizó para la aplicación e implementación de los algoritmos de entrenamiento y se realizó en un ambiente que corre en la nube donde sus características son:

- 4 procesadores Intel(R) Xeon(R) CPU @ 2.20GHz
- 25 GB de memoria RAM

Se utilizó el lenguaje de programación Python versión 3.7 y se utilizó el framework tensorflow 2.0



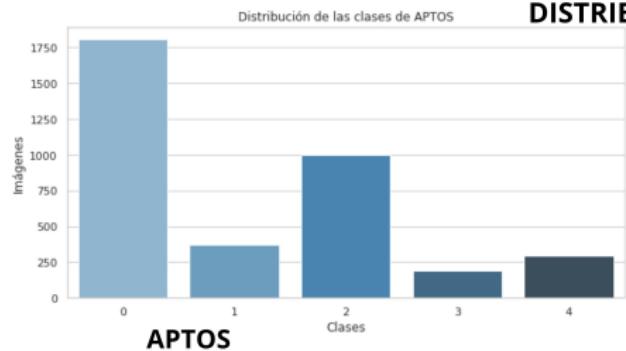
Experimentos

Experimento 1	No se aplicaron filtros.
Primeras técnicas utilizando redes neuronales conv.	Se utilizo softmax con 5 clases y entropia cruzada. Adam, lotes de 34 imágenes de 224*224*3. Arquitectura con 5 capas convolucionales de 32, 64, 128, 256 y 512 filtros de 3*3 y 2 capas completamente conectadas de 512 y 128 neuronas.
Experimento 2	Experimentar con ResNet50, DenseNet50, aplicar filtro.
Procedimientos recientes con arquitecturas profundas.	Aumentación de datos. Transferencia de aprendizaje. Monitoreo del coeficiente kappa y cuando mejoraba se guardaban los pesos.
Experimento3	-EfficientNet. -Suavizado de etiquetas.
Metodología	-Validación cruzada. -Media recortada para eliminar valores atípicos. -Ensamble. -Transferencia de aprendizaje con EyePacs. -Entrenar ⁵ partes de la Arquitectura. -TTA

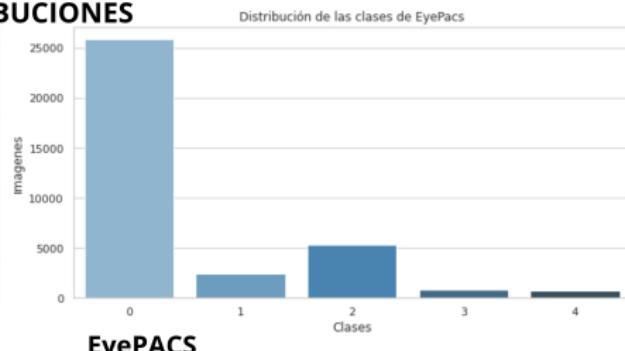


Distribución de los Datos

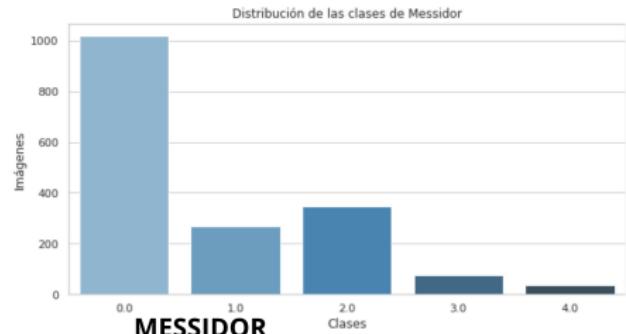
DISTRIBUCIONES



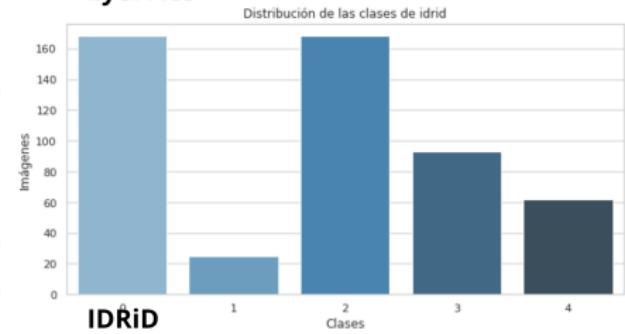
APTOPS



EyePACS

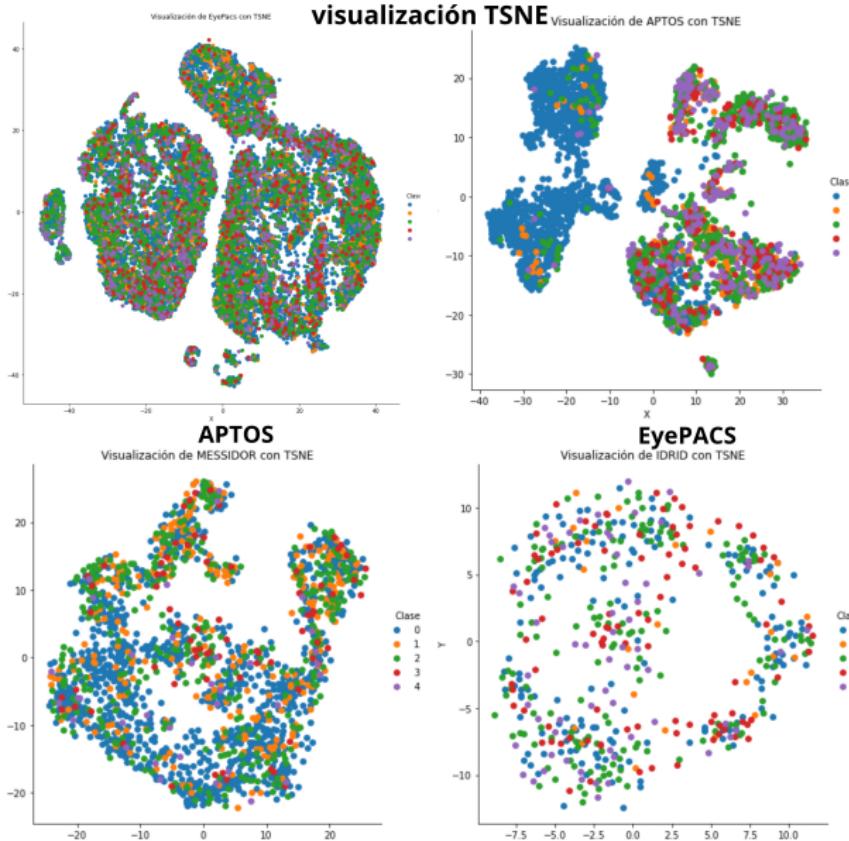


MESSIDOR

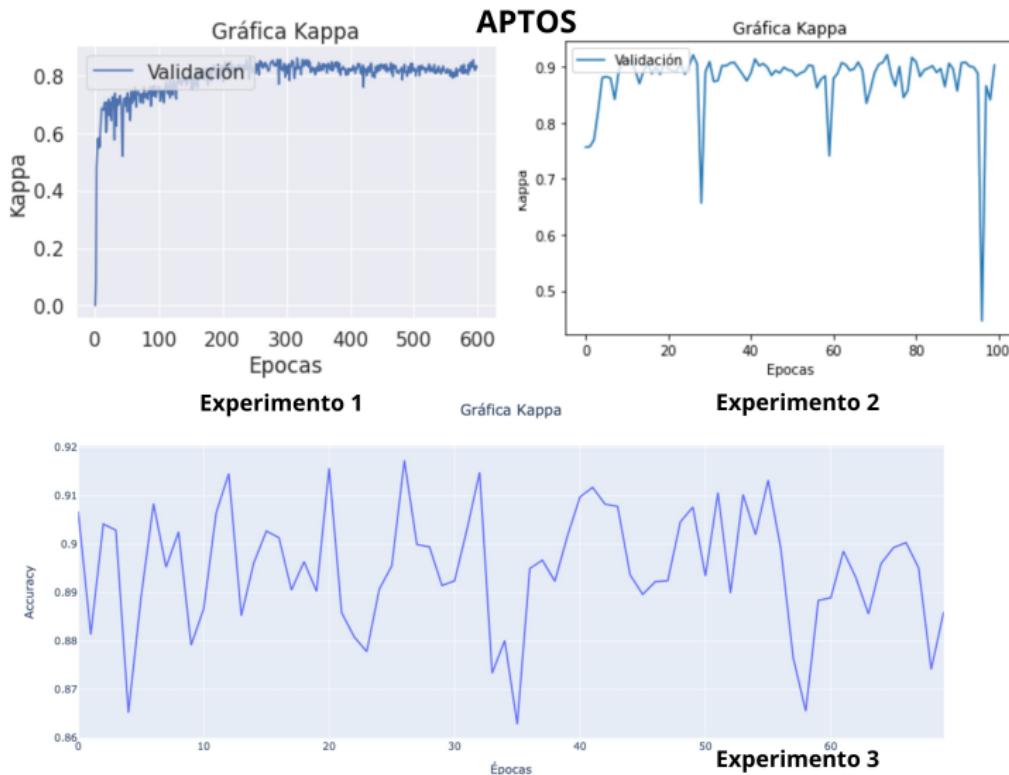


IDRiD

Visualización T-SNE

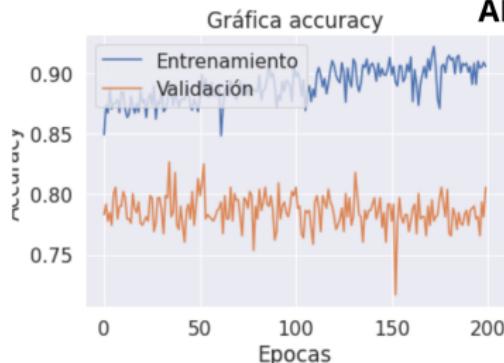


Evolución de la puntuación Kappa

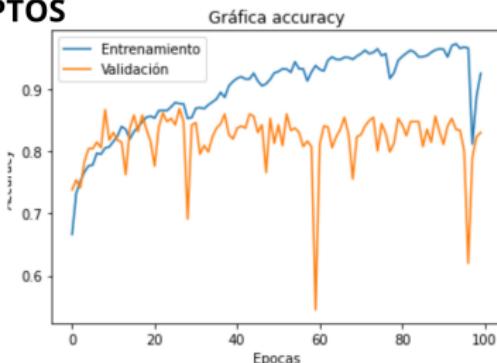


Evolución de la Exactitud

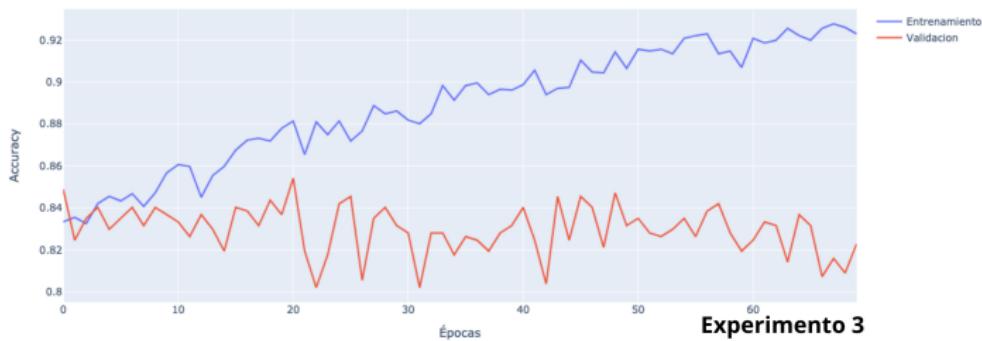
APTOPS



Experimento 1



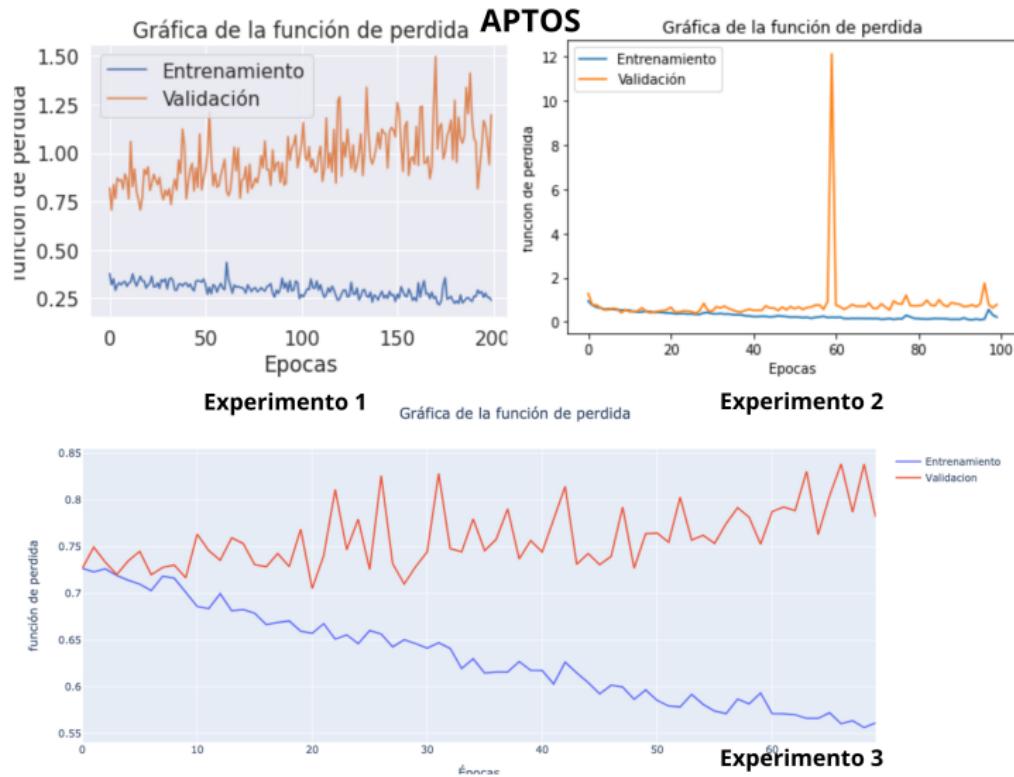
Experimento 2



Experimento 3



Evolución de la Pérdida



Matriz de confusión

0 - No DR	371	5	7	0	1
1 - Leve	6	21	40	2	1
2 - Moderada	6	12	153	8	1
3 - Severa	0	1	26	7	5
4 - Proliferativa DR	0	2	39	5	14

Experimento 1

0 - No DR	376	7	1	0	0
1 - Leve	0	46	23	0	1
2 - Moderada	0	15	142	17	6
3 - Severa	0	0	15	18	6
4 - Proliferativa DR	0	3	20	8	29

Experimento 2

0 - No DR	382	4	0	0	0
1 - Leve	5	38	15	0	1
2 - Moderada	0	19	163	16	19
3 - Severa	0	0	1	15	3
4 - Proliferativa DR	0	0	6	4	42

Experimento 3

0.97	0.01	0.02	0.00	0.00
0.09	0.30	0.57	0.03	0.01
0.03	0.07	0.85	0.04	0.01
0.00	0.03	0.67	0.18	0.13
0.00	0.03	0.65	0.08	0.23

0 - No DR	0.98	0.02	0.00	0.00	0.00
1 - Leve	0.00	0.66	0.33	0.00	0.01
2 - Moderada	0.00	0.08	0.79	0.09	0.03
3 - Severa	0.00	0.00	0.38	0.46	0.15
4 - Proliferativa I	0.00	0.05	0.33	0.13	0.48

0 - No DR	0.99	0.01	0.00	0.00	0.00
1 - Leve	0.08	0.64	0.25	0.00	0.02
2 - Moderada	0.00	0.09	0.75	0.07	0.09
3 - Severa	0.00	0.00	0.05	0.79	0.16
4 - Proliferati	0.00	0.00	0.12	0.08	0.81



Cálculo de las medidas de desempeño

Etiquetas	Predicciones		
	VN	FP	VN
	FN	VP	FN
	VN	FP	VN

$$\text{Sensibilidad} = \frac{VP}{VP+FN}$$

$$\text{Especificidad} = \frac{VN}{VN+FP}$$

Coeficiente Kappa

$$K = \frac{m \sum_{i=1}^C X_{di} - \sum_{i=1}^C X_{fi} X_{ci}}{m^2 - \sum_{i=1}^C (X_{fi} X_{ci})}$$

0 - No DR	382	4	0	0	0
1 - Leve	5	38	15	0	1
2 - Moderada	0	19	163	16	19
3 - Severa	0	0	1	15	3
4 - Proliferativa DR	0	0	6	4	42



$$\text{Sensibilidad}_0 = \frac{382}{382+4} = 0.98$$

$$\text{Especificidad}_0 = \frac{342}{342+5} = .98$$



Tablas con medidas de desempeño

Experimento 1 y 2

BD	Kappa	Exactitud	Precisión	(E)	(S)	Macro F1	Épocas	Parámetros
APTOPS	0.844	0.778	0.627	0.942	0.550	0.570	300	14,480,453
EyePacs	0	0.726	0.145	0.8	0.200	0.168	200	14,480,453
Messidor	0.439	0.617	0.413	0.854	0.376	0.376	520	14,480,453
IDRiD	0.375	0.359	0.249	0.827	0.256	0.250	500	14,480,453

-	Kappa	Exactitud	Precisión	(E)	(S)	Macro-F1	Parámetros	Épocas
DenseNet APTOPS	0.908	.829	0.713	0.956	0.620	0.641	8,092,229	100
ResNet Messidor	0.718	0.763	0.491	0.9	0.384	0.373	27,794,309	100
DenseNet IDRiD	0.693	0.553	0.413	0.87	0.413	0.371	8,092,229	100

Experimento 3

Metodología	Kappa	Exactitud	Precisión	(E)	(S)	Macro-F1	Parámetros	Épocas
APTOPS	0.923	.843	0.719	0.960	0.653	0.675	32,720,117	80
Messidor	0.817	0.780	0.728	0.910	0.554	0.570	32,720,117	80
IDRiD	0.713	0.641	0.490	0.89	0.476	0.468	32,720,117	80

Resultados

Tablas con la comparación de los resultados de 3 metodologías incluyendo la propuesta para 3 conjuntos de datos

APTOPS	Kappa	Exactitud	Precisión	(E)	(S)	Macro F1	Parámetros	Épocas
Exp1	0.844	0.778	0.627	0.942	0.550	0.570	14,480,453	300
Exp2	0.908	0.829	0.713	0.956	0.620	0.641	8,092,229	100
Exp3	0.923	0.843	0.719	0.960	0.653	0.675	32,720,117	80

APTOPS

Messidor	Kappa	Exactitud	Precisión	(E)	(S)	Macro F1	Parámetros	Épocas
Exp1	0.439	0.617	0.413	0.854	0.376	0.376	14,480,453	520
Exp2	0.727	0.683	0.463	0.90	0.451	0.455	8,092,229	100
Exp3	0.817	0.780	0.728	0.910	0.554	0.570	32,720,117	80

Messidor

IDRiD	Kappa	Exactitud	Precisión	(E)	(S)	Macro F1	Parámetros	Épocas
Exp1	0.375	.359	0.249	0.827	0.256	0.250	14,480,453	500
Exp2	0.693	0.553	0.413	0.87	0.415	0.371	8,092,229	100
Exp3	0.713	0.641	0.490	0.89	0.476	0.468	32,720,117	80

IDRiD

Metodología



Conclusiones

- Los resultados de la metodología se pueden verificar en las tablas anteriores, donde se obtuvieron mejoras en 3 conjuntos de datos con respecto a 2 metodologías en el estado del arte. Mejorando en el coeficiente Kappa, en la exactitud y algunas otras medidas de desempeño. Los resultados obtenidos se realizaron sobre un conjunto de prueba de 3865 ejemplos para el primer conjunto de datos, 1750 para el segundo y 515 en el tercero.

Para mas referencias ver <https://github.com/jaycko2791/Tesis>.



Trabajo a futuro

- Calcular y realizar el análisis de Explicaciones de aditivos SHapley[12].
- Utilizar descriptores clásicos o técnicas de visión artificial.
- Utilizar transformadores[13] o LambdaNetworks[14].
- Poner en producción la red neuronal mediante un servicio web que ayude a diferentes clínicas en la toma de decisiones.

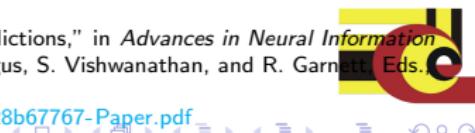


GRACIAS POR SU ATENCIÓN



Bibliografía I

- [1] OMS, "Diabetes, datos y cifras," 2020. [Online]. Available: <https://www.who.int/es/news-room/fact-sheets/detail/diabetes>
- [2] T. E. Rohan, C. D. Frost, and N. J. Wald, "Prevention of blindness by screening for diabetic retinopathy: a quantitative assessment." *British Medical Journal*, vol. 299, no. 6709, pp. 1198–1201, 1989.
- [3] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Commun. ACM*, vol. 60, no. 6, p. 84–90, May 2017. [Online]. Available: <https://doi.org/10.1145/3065386>
- [4] D. C. Ciresan, U. Meier, L. M. Gambardella, and J. Schmidhuber, "Deep, big, simple neural nets for handwritten digit recognition," *Neural Computation*, vol. 22, no. 12, p. 3207–3220, Dec 2010. [Online]. Available: http://dx.doi.org/10.1162/NECO_a.00052
- [5] Y. Lecun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, pp. 2278 – 2324, 12 1998.
- [6] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv 1409.1556*, 09 2014.
- [7] M. Lin, Q. Chen, and S. Yan, "Network in network," *CoRR*, vol. abs/1312.4400, 2013.
- [8] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. E. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun 2014. [Online]. Available: <http://dx.doi.org/10.1109/CVPR.2015.7298594>
- [9] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [10] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2261–2269.
- [11] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," *CoRR*, vol. abs/1905.11946, 2019. [Online]. Available: <http://arxiv.org/abs/1905.11946>
- [12] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30. Curran Associates, Inc., 2017, pp. 4765–4774. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf>



Bibliografía II

- [13] Anonymous, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Submitted to International Conference on Learning Representations*, 2021, under review. [Online]. Available: <https://openreview.net/forum?id=YicbFdNTTy>
- [14] ——, "Lambdanetworks: Modeling long-range interactions without attention," in *Submitted to International Conference on Learning Representations*, 2021, under review. [Online]. Available: <https://openreview.net/forum?id=xTJEN-ggl1b>
- Harry Pratt, Frans Coenen, D. M. B. S. P. H. Y. Z. (2016). Convolutional neural networks for diabetic retinopathy.
 - Shaohua Wan, Yan Liang, Y. Z. (2018). Deep convolutional neural networks for diab
 - Carson Lam, Darvin Yi, M. G. and Lindsey, T. (2018). Automated detection of diabetic retinopathy using deep learning.
 - Hagos, M. T. and Kant, S. (2019). Transfer learning based detection of diabetic retinopathy from small dataset. CoRR, abs/1905.07203.
 - Rubina Sarki, Sandra Michalska, K. A. H. W. Y. Z. (2019). Convolutional neural networks for mild diabetic retinopathy detection: an experimental study.bioRxiv.

